Projektbericht

Danceable – Tanzerkennungssoftware

Tobias Huch, Samuel Mayer, Zoe Öllinger, Luca Zinhobel

Gender-Erklärung

Zur besseren Lesbarkeit wird in dem folgenden Text auf die gleichzeitige Verwendung männlicher und weiblicher Sprachformen verzichtet. Es wird das generische Maskulinum verwendet, wobei weibliche, männliche und diverse Personen gleichermaßen gemeint sind.

Inhalt

1. PROJEKTDOKUMENTATION 2

1.1 PROJEKTENTSTEHUNG- UND PLANUNG 2

1.2 INHALTLICHE BESCHREIBUNG DER UMSETZUNG 3

1.3 KUNDENNUTZEN 10

1.4 AUSBLICK UND KOMMERZIELLE VERWERTBARKEIT 10

1.5 BERICHT DES PROJEKTKOORDINATORS 12

2. ABBILDUNGS- UND LITERATURVERZEICHNIS 13

1. Projektdokumentation

1.1 Projektentstehung- und Planung

Die Idee zu einer Tanzerkennungssoftware kam als erstes unserem Projektleiter Tobias Huch, als er während seinem Tanzkurs die Unsicherheit mancher bei der Tanzauswahl beobachten konnte. Diese Unsicherheit führte oft dazu, dass am Anfang eines Liedes nicht getanzt wurde, bis ein Tanzlehrer den Anstoß gab oder sich manche Tanzschüler auf Bällen oder anderen Events gar nicht erst auf die Tanzfläche trauten. Es entstand die Vision einer Smartphone-App, die, ähnlich wie Musikerkennungsprogramme, auf Knopfdruck den passenden Tanz vorhersagen könnte. Nach ausgiebiger Recherche fand sich jedoch keine existente Lösung dafür, weswegen sich unser Projektteam zusammenfand und beschloss, sich dessen anzunehmen.

Das Ziel des Projektes ist es, Tanzenden mit weniger Erfahrung die Tanzauswahl zu einem Lied zu erleichtern. Da angehende Tanzende den passenden Tanz zur spielenden Musik zeitnah brauchen, soll dies mithilfe einer Smartphone-App umgesetzt werden.

Wir gingen somit davon aus, dass es möglich wäre, mit lediglich drei Sekunden langen Ausschnitten aus einem Musikstück den am besten passenden Paartanz aus einer zuvor vorgegeben Auswahl aus zehn Tanzstilen zu einem Lied mithilfe eines Deep-Learning KI-Modells zu finden.

Gerade am Anfang unseres Projektes waren viel Recherche und viele fachübergreifende Gespräche mit Mathematik-, Physik- und Audiotechnikprofessoren unserer Schule notwendig, um Konzepte wie die Fourier-Analyse, Mel-Frequenz-Cepstrum-Koeffizienten oder Root-Mean-Square-Energy zu verstehen, mit denen keiner von uns zuvor Kontakt hatte, die aber essenziell waren, um die zugrunde liegenden Konzepte der Tanzerkennung zu verstehen und somit später im Projekt begründete Annahmen treffen zu können. Auch das Wissen, das für unsere KI benötigt wurde, ging weit über den Unterrichtsrahmen des Schulfachs „KI und Data Science“, jedoch fanden wir auch hier unterstützende Lehrkräfte.

Um zu überprüfen, wie realistisch unsere These war, mussten wir mit einem Proof of Concept die Durchführbarkeit unseres Projektes beweisen. Unseren ersten großen Meilenstein hatten wir somit erreicht, als wir durch anfangs noch händische Analyse von

Audiodateien gewisse Muster erkennen konnten, die Rückschlüsse auf den richtigen Tanz lieferten. Weitere große Schritte im Geschehen unseres Projektes waren der Aufbau einer zentralen Kommunikationsschicht zwischen App, Server und Machine Learning Komponente, das Trainieren eines ersten KI-Modells, Fertigstellung von IOS und Android App, sowie Auslieferung der App and die Schul-Kubernetes-Cloud und das Erreichen einer Accuracy von 70% bei der Tanzerkennung.

1.2 Inhaltliche Beschreibung der Umsetzung

Während Apps wie zum Beispiel Shazam anhand von Fingerprints die aufgenommene Audio einem Song aus einer Datenbank zuweisen, setzten wir uns das Ziel, tatsächliche Muster in der Musik zu erkennen. Dadurch wollen wir sicherstellen, dass unsere Software nicht nur mit vorher bekannter Musik funktioniert, sondern auch mit Livemusik oder nie gehörten Musikstücken gut umgehen kann. Eine App wie unsere, die Tanzstile aufgrund von Rhythmikmustern in der Musik hervorsagt, gibt es trotz vereinzelter Versuche bisher in keiner Weise.

Eine weitere wichtige Entscheidung war der Erkennungsumfang der Anwendung, also welche Tanzstile überhaupt durch KI-basierte Tanzerkennung erkannt werden sollten. Unter Absprache mit einem Tanzlehrer unser Teammitglieder einigten wir uns auf zehn der wichtigsten und etabliertesten Standard-, Latein- und Trendtänze. Die Liste besteht aus: Cha-Cha-Cha, Discofox, Jive, Quickstep, Tango, Rumba, Salsa, Samba, Langsamer Walzer und Wiener Walzer. Somit können wir den größten Teil der in deutschsprachigen Tanzschulen unterrichteten Tänze abdecken.

Das Herz unseres Projekts ist die Tanzerkennung. Da unsere Annahme darauf basiert, dass wir durch wiederkehrende musikalische Elemente bzw. Merkmale, wie Tempo, Takt oder Betonungsmuster, einen Tanz zuweisen können, begannen wir unser Projekt damit, Audiodateien von Liedern zu untersuchen. Die ersten Schritte waren im Plenum Audiowellen zu analysieren und zu vergleichen. Unser Physiklehrer führte uns in die Fourier-Transformation ein, ein mathematisches Verfahren, das es ermöglicht, eine Tonspur in ihre spektralen Frequenzanteile zu zerlegen und dadurch die einzelnen Bausteine der Frequenz systematisch zu analysieren. Parallel begannen wir mit einem anderen Ansatz, die Tänze nur nach dem Tempo einzuteilen. Nachdem wir beim ersten Ansatz Potential erkannten – wir konnten bereits anhand der Visualisierung der Short Fourier

Transformation Rückschlüsse auf bestimmte Tänze ziehen und bestimmte Muster erkennen – gingen wir genauer darauf ein.

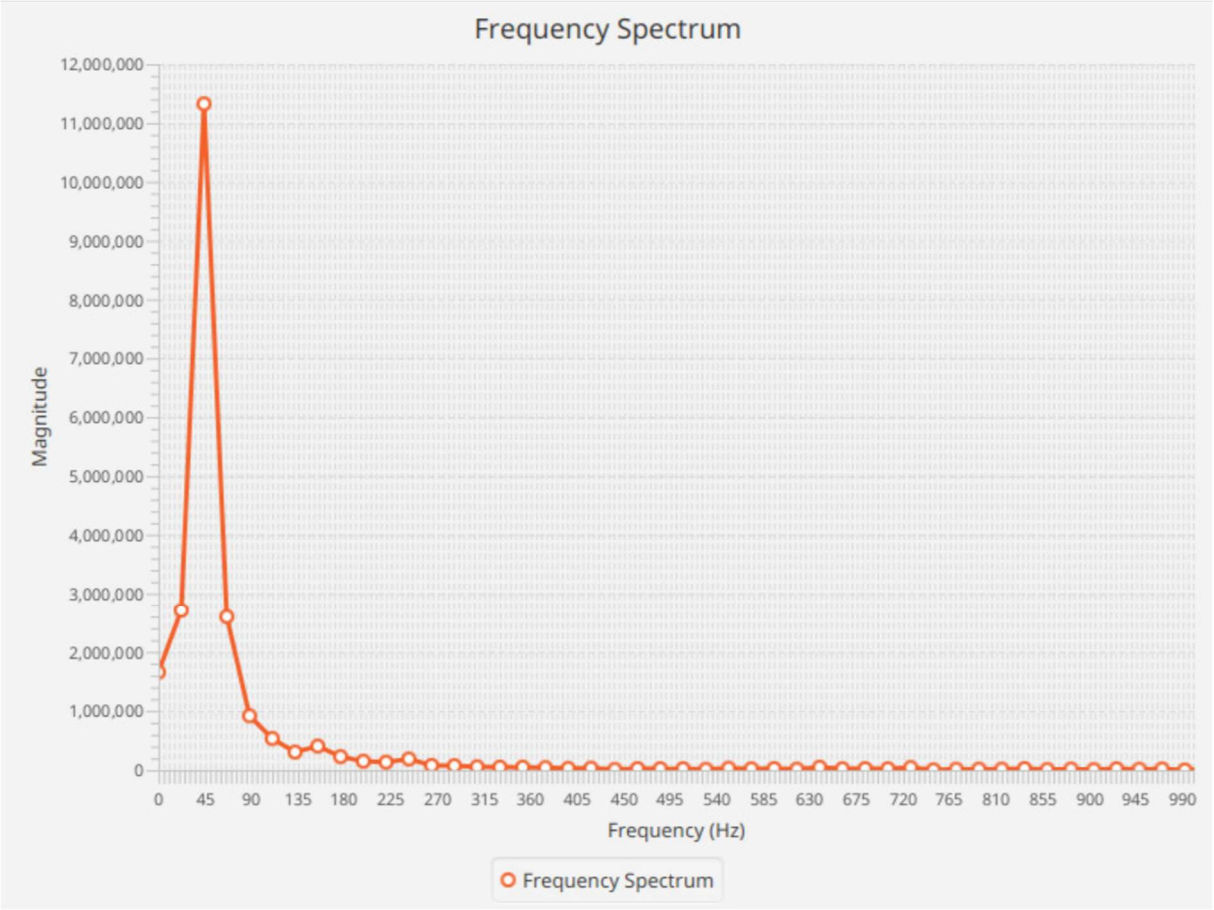

Abbildung 1: Graphische Visualisierung des Ergebnisses einer händischen Fourier-Analyse

Sogenannte Features sind Merkmale, anhand welcher eine KI-Daten analysiert. Eine unserer Hauptaufgaben war es, geeignete Features zu finden, welche der KI zur Erkennung von Tänzen nutzen könnten. Hier galt es vor allem, herauszufinden, ob die Fourier Transformation allein als Feature ausreichend könnte, oder die KI zusätzlich mit anderen Informationen gefüttert werden musste. Schnell wurde klar, dass die Fourier Transformation allein nicht ausreichte, und eine eigene Umsetzung verschiedenster audiotechnischer Kennwerte zu aufwendig war, weswegen wir auf externe Libraries zurückgriffen, mit denen wir Audio anhand von verschiedensten Metriken analysieren konnten. Dieser Ansatz ermöglichte auch ein schnelles Wechseln von Features, um die relevantesten Faktoren für die Tanzerkennung zu finden, ohne dass zu viel Zeit unserem Team verloren ging.

Da wir nicht ausreichend bereits klassifizierte Trainingsdaten finden konnten, waren wir gezwungen, sie selbst zu klassifizieren. Zwei unserer Teammitglieder waren dafür

zuständig, große Mengen an Tanzmusik herunterzuladen, den richtigen Tanz zuzuordnen und geeignete Stellen auszuwählen.

Hier ist es wichtig zu erwähnen, dass aufgrund der unserem KI-Modell zugrunde liegenden Algorithmen, jedem Musikstück nur ein Tanz zugeordnet wurde, obwohl es nicht unüblich ist, dass zu einem Lied mehrere Tänze passen und sich selbst Tanzlehrer und erfahrene Tänzer nicht entscheiden können.

Im Schulfach KI und Data Science wurde uns vermittelt, dass zur Minimierung von Verzerrungen die Länge der Trainingsdaten mit der Länge der später zur Erkennung verwendeten Daten übereinstimmen muss. Die Schwierigkeit lag darin, die Waage zwischen ausreichender Zeit für zuverlässige Klassifizierung und möglichst kurzer Wartezeit bei der Erkennung zu finden. Auch bieten kürzere einzelne Audioclips zwar weniger Information, jedoch lassen sich Tanzlieder auch in mehr dieser kurzen Dateien aufteilen, und unser Modell erhält somit mehr Variation. Nach einigen Versuchen kamen wir auf eine Zeitspanne von drei Sekunden, eine Dauer unter unseren anfänglichen Schätzungen von rund zehn Sekunden, die einerseits gutes Training als auch eine gute User Experience sicherstellte.

Das Machine Learning selbst haben wir mithilfe des Python Frameworks Tensor Flow entwickelt, welches als der Industriestandard gilt. Nach ersten Versuchen mit komplexeren Modellen wurde klar, dass die Rechnerkapazitäten unserer eigenen Computer nicht ausreichend waren. Aus diesem Grund brachten wir das Training in die Cloud. Unsere Schule stellte uns die schulinterne „Leo-Cloud“ zur Verfügung, auf der mithilfe von Kubernetes das Training nun verteilt auf mehrere Server in viel geringerer Zeit stattfinden konnte. Ein wesentlicher Innovationsschritt bestand hier im Vergleich verschiedener Modellansätze, also dem Ausprobieren verschiedener Kombinationen an Algorithmen mit verschiedenen Kombinationen an Features. Durch diese Verfahren wurde auch der Wechsel zu einem Convolutional Neural Network (CNN) möglich, welches zu einer verbesserten Erkennung führte und Daten unabhängig von der Audioqualität klassifizieren konnte.

Es wurden verschiedene Ansätze diskutiert, welche Art von Ergebnis die KI liefern sollte. Die Überlegungen reichten von der Ausgabe eines einzelnen erkannten Tanzstils bis hin zur Berechnung individueller Wahrscheinlichkeits- beziehungsweise Confidence-Werte für jeden Tanz. Schlussendlich wurde beschlossen, einen prozentualen Confidence-

Wert auszugeben, der sich über alle erkannten Tanzstile hinweg zu 100 % aufsummiert. So ist die Erkennung auch bei Liedern, die potenziell zu mehreren verschiedenen Tanzstilen passen könnten, transparenter.

Um beurteilen zu können, wie leistungsfähig das aktuelle Machine-Learning-Modell war, wurde fortlaufend die „Accuracy“ als zentrale Bewertungskennzahl berechnet. Diese beschreibt in Prozent, bei wie vielen der KI zuvor unbekannten Musik-Snippets der richtige Tanz erkannt wird und wird ergänzt durch den Loss-Wert, der die durchschnittliche Abweichung der Vorhersagen von den tatsächlichen Kategorien misst. Wie bereits erwähnt zeigt sich hierbei erneut die Problematik überschneidender Tanzstile. In solchen Fällen kann es vorkommen, dass die KI faktisch ein plausibles Ergebnis liefert, dieses jedoch aufgrund der gewählten Bewertungslogik dennoch als falsch klassifiziert wird.

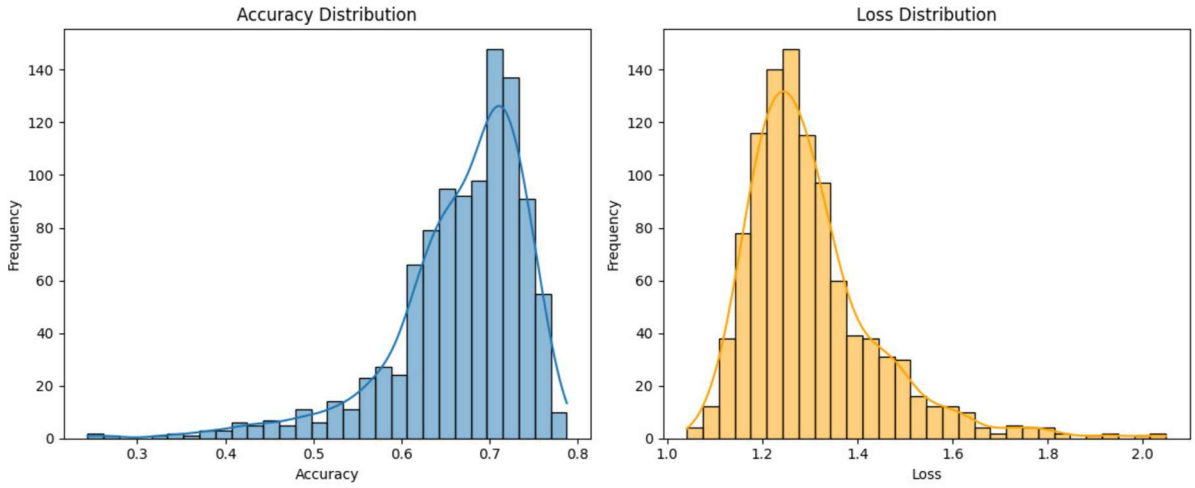

Abbildung 2: Verteilung von KI-Modellen mit unterschiedlicher Auswahl an Features

Im nächsten Experiment wollten wir unser Modell feinjustieren. Dafür wurde die KI mit verschiedenen Gewichtungen bzw. anderen Hyperparametern immer wieder neu trainiert. Auch dieser Prozess wurde aus Effizienzgründen auf der Cloud durchgeführt und dauerte mehrere Tage. Zu jedem Modell wurde dann die Accuracy berechnet und verglichen. Das beste Modell konnte eine Accuracy von über 70% aufweisen.

Um die KI dem Nutzer zugänglich zu machen waren zu Beginn eine Web- und eine Mobile Applikation (IOS und Android) in Planung. Nach genauerem Untersuchen der Anwendungsfälle wurde die Web-Version jedoch verworfen und mehr Fokus auf die Apps gelegt. Um für beste User Experience zu sorgen, wurden die Apps in Native Frameworks SwiftUI

und Jetpack Compose entwickelt. Während die IOS-App bereits fertiggestellt wurde, ist die Android App noch in Entwicklung. In diesen Apps gibt es die Möglichkeit, einen Record-Button zu drücken und anschließend die passenden Tänze zur spielenden Musik angezeigt bekommen. Das Design der Applikationen wurde im Vorhinein als Wireframe realisiert, um klare Richtlinien für die Umsetzung beider Apps zu haben.

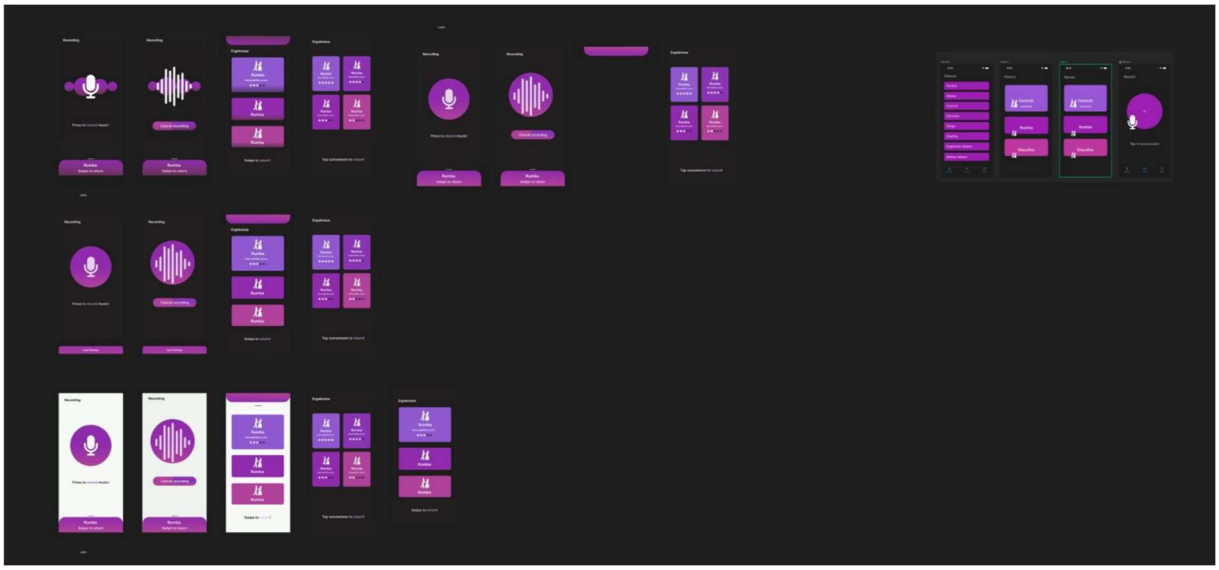

Abbildung 3: Auszug des Wireframes für unsere App

Besonders hervorzuheben ist, dass ein modernes iOS-Features namens CoreML genutzt wurde, um die Ausführung von KI-Modellen direkt auf dem Endgerät zu ermöglichen, wodurch der Weg für eine lokale und effiziente Verarbeitung geebnet wird. Durch einen exportierten Lookup Table können wir auf IOS-Geräten die Klassifizierung lokal stattfinden lassen und eliminieren so die Kommunikationszeit mit dem Server, was die benötigte Zeit zur Erkennung in extremen Fällen von ca. fünf Sekunden auf ungefähr drei Sekunden reduzieren kann und dafür sorgt, dass unsere App ohne Internetverbindung verwendet werden kann, was gerade in Ballsälen mit vielen Gästen und schlechter Mobilfunkverbindung relevant ist.

Aufgrund von Sicherheitsbedenken wollten wir vermeiden, dass unser KI-Python-Server direkt mit den Client Anwendungen kommuniziert. Zwischen den beiden wurde ein Java Server installiert, welcher sich um das Empfangen der Audioaufnahmen, als auch um die Aufbereitung der Tanzvorhersagen kümmert. Dieser Zwischen- als auch der KI-Server sind auch Teil der Cloud und können somit bedarfsweise horizontal skaliert werden.

Aktuell erkennt unsere Applikation 75% von ungesehenen Testdaten richtig. Die exakte Genauigkeit ist anschließend in einer sogenannten Confusion Matrix (Abb. 4) aufgeschlüsselt. Auf der y-Achse ist der korrekte Tanz aus den Testdaten angeführt, während auf der x-Achse der von unserem KI-Modell erkannte Tanz eingetragen ist. Am Treffpunkt von tatsächlicher und erkannter Tanzrichtung findet sich eine Prozentzahl, die angibt, wie viele Lieder mit einer tatsächlichen Tanzrichtung als eine bestimmte erkannt wurden. Am Beispiel des zweiten Kästchens ganz oben links (Reihe 1, Spalte 2): 24.5% der Audiodateien, zu denen man einen Cha-Cha-Cha (abk. ChaCha) tanzen sollte, werden als Discofox erkannt.

Hier ist es erneut wichtig, die Mehrdeutigkeit bestimmter Musikstücke hervorzuheben, da einzelne Lieder mehreren Tanzstilen zugeordnet werden können. Cha-Cha-Cha und Discofox haben beispielsweise extrem hohe Überschneidungen, da die passenden Lieder sehr ähnlich sind und es oft möglich ist, beides zu tanzen.

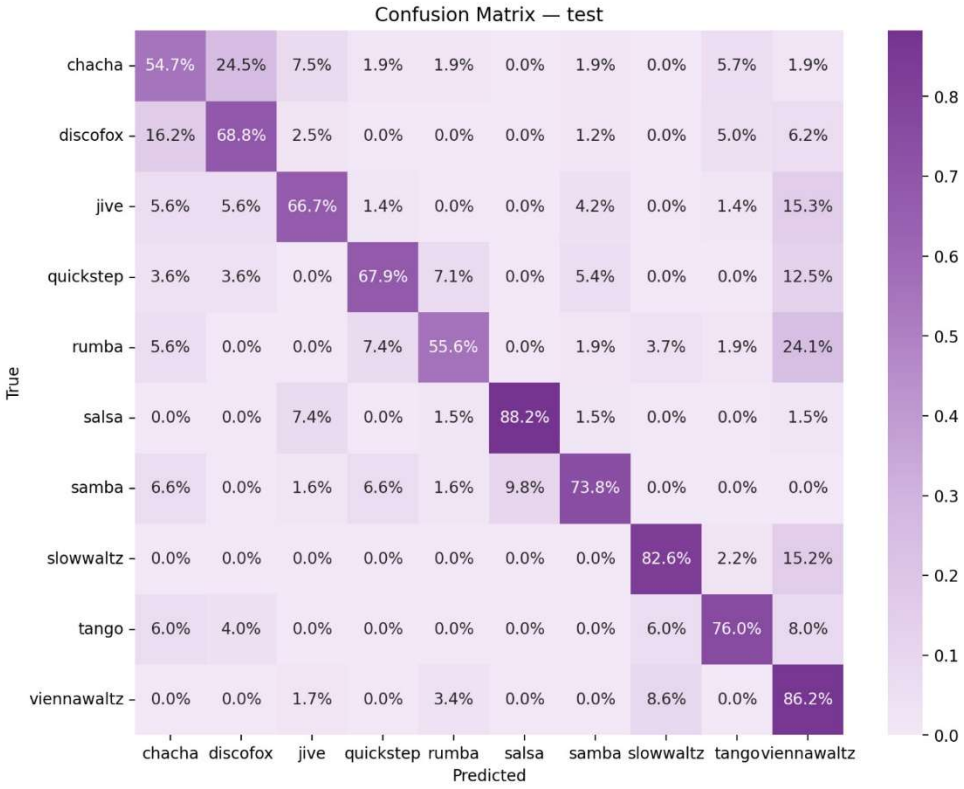

Abbildung 4: Confusion Matrix

Im Anschluss ist die Confusion Matrix ebenfalls als 3D-Visualisierung angefügt. (Abb. 5) Hier ist die Farbe oder Genauigkeit zusätzlich durch die Höhe dargestellt. Desto tiefer das „Tal“, desto höher die Wahrscheinlichkeit.

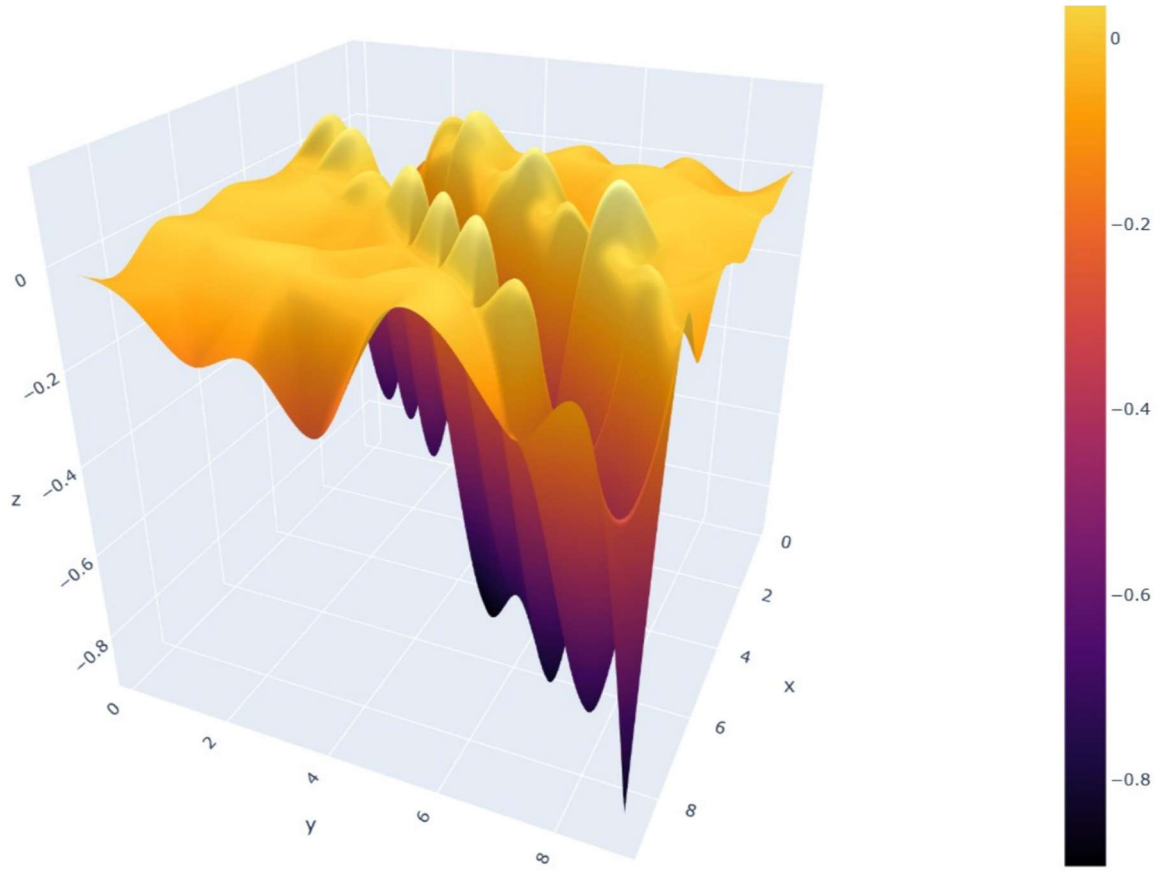

Abbildung 5: 3D-Visualiserung der Confusion Matrix

Wir trafen am Anfang unseres Projekts die Entscheidung, Urheberrechte während der Entwicklung zu vernachlässigen, um die Entwicklung nicht unnötig aufzuhalten und die Trainingsdaten im Falle einer Kommerzialisierung durch urheberrechtlich erworbene Daten zu ersetzen. Über die Laufzeit des Projekts hat sich ein Interessent dafür bereit erklärt, im Falle einer Zusammenarbeit selbst rechtlich unbedenkliche Daten für das Training zur Verfügung zu stellen.

Aus den Resultaten zum Zeitpunkt der Abgabe dieses Berichts kann man die Schlussfolgerung ziehen, dass unsere These sich weitestgehend als richtig herausgestellt hat. Bis auf mehrdeutige Ergebnisse und manche Ausnahmen ist es unserem Modell möglich, die zu einem Lied passenden Tänze zuverlässig vorherzusagen. Eine Herausforderung bleibt zu diesem Zeitpunkt noch die Erkennung von manchen Tänzen mit 4/4-Takt (z.B. Jive, Rumba, Quickstep) als Wiener Walzer mit 3/4 Takt, da zu diesen Tänzen passende Musikstücke grundsätzlich eindeutig klassifizierbar sein sollten. Diese Hürde bedarf in naher

Zukunft einer Unterteilung unseres KI-Modells, in der als erstes zwischen Taktarten und erst infolgedessen zwischen Tänzen in diesen Taktarten unterschieden werden wird.

1.3 Kundennutzen

Unser Projekt nutzt unseren Usern dahingehend, dass ihre Unsicherheiten bei der Erkennung von richtigen Tänzen sie nicht länger davon abhalten, die ersten auf der Tanzfläche zu sein, vor allem, weil diese Unsicherheiten oft nicht auf das Tanzen selbst übertragbar sind. Viele Tanzschüler können weit besser tanzen, als den Tanzstil zu einem Lied erkennen und werden jetzt nicht länger dadurch eingeschränkt. Wir wollen sicherstellen, dass eine weniger ausgeprägte Tanzerkennung keinem das Gefühl des Tanzens vorenthalten kann und damit unseren Beitrag dazu zu leisten, Tanzen einen Schritt zugänglicher für alle zu machen.

Beide unserer einer Tanzschule angehörigen Teammitglieder haben diese Idee einigen Mittänzern vorgestellt und sind dabei auf fast ausschließlich positives Feedback gestoßen.

1.4 Ausblick und kommerzielle Verwertbarkeit

Bis zum Abschluss dieses Schuljahres wird unser vierköpfiges Team weiter an unserem Projekt arbeiten. Konkret werden wir Änderungen am KI-Modell vornehmen, die Android App fertigstellen und einige kleine Abweichungen vom Soll-Zustand der App ausbessern.

Nach Abschluss des Projektes gibt es mehrere Möglichkeiten für den weiteren Verlauf von „Danceable“:

Es besteht zum einen die Möglichkeit, das Projekt mit dem gesamten oder einem Teil des Teams weiterzuführen und als B2C Lösung für Tanzschüler anzubieten. Unser bevorzugtes Geschäftsmodell für diesen Fall wäre die Tanzerkennung als kostenfreie Basisfunktion, um die Einstiegshürde für Erstnutzer zu minimieren. Wir würden für kostenpflichtige Abonnenten die Funktionalität der App erweitern und Lernmodi hinzufügen, bei denen man die Grundschritte oder Takte der erkannten Tänze sehen könnte, um auch Neulinge des Tanzens ansprechen zu können. Zu den kostenpflichtigen Funktionen würde außerdem eine History zählen, bei der man bereits analysierte Musikstücke nochmals anschauen könnte, um sie beispielsweise einer Playlist hinzuzufügen oder dazu zu

bestimmte Tänze zu üben. Für dieses Feature würden wir eine Musikerkennungs-API wie zum Beispiel audd.io (https://audd.io/) oder AcousticBrainz (https://acousticbrainz.org/) einbinden, damit zum Lied gehörige Daten, wie Titel und Künstler, angezeigt werden können. Bei Verwendung einer API wie AcousticBrainz gäbe es auch die Möglichkeit, über einen generierten Fingerprint eines Liedes dem User ähnliche Titel in unserer App vorzuschlagen. Auch Zeitpunkt und Standort der erkannten Tänze würden angezeigt werden, um Livemusik, die natürlich in einer Liederkennungsdatenbank nicht vorhanden wäre, eindeutig zuweisbar zu machen. Das Abonnement wäre mit ca. 3-7€ im Monat in einem erschwinglichen Bereich für Tanzschüler, die ohnehin monatlich ein Vielfaches dessen für die Tanzschule bezahlen. In Kombination mit einem kostenfreien Testzeitraum bliebe die Hemmschwelle niedrig und die App würde ihren Mehrwert schnell demonstrieren. Weiterhin könnte man durch Kooperationen mit Tanzschulen Rabatte arrangieren und im Gegenzug die Bekanntheit des Produkts erhöhen.

Alternativ wären institutionelle Lizenzen für Tanzschulen denkbar, bei der die App mit kundenspezifischer Marktidentität und individueller Eingliederung in das Lernprogramm einzelner Tanzschulen spezifischangepasst wird. Nach dem Erkennen eines Tanzes könnte der Benutzer zum Beispiel auf ein Video der Tanzschule zum Grundschritt oder einfachen Figuren in dem erkannten Tanzstil weitergeleitet werden. Dieser Ansatz würde planbarere, stabilere Einnahmen garantieren und den Marketingaufwand für eine grundsätzliche Bekanntheit in der Branche reduzieren, sofern Tanzschulen bereit sind, in das Konzept zu investieren.

Es gibt auch die Möglichkeit, die obigen Ansätze zu kombinieren und zuerst mit minimalen Marketingausgaben und Fokus auf Mund-zu-Mund-Propaganda einen kleinen Kundenstamm aufzubauen, so Tanzschulen von dem Konzept zu überzeugen und dann entweder ganz auf institutionelle Lizenzen umzusteigen oder beide Modelle parallel zu betreiben.

Ein völlig alternativer Ansatz wäre, nur das KI-Modell an einen bereits identifizierten Interessenten weiterzugeben. Einzelne Projektmitglieder würden eventuell in der Firma weiterarbeiten und die Tanzerkennungs-KI in eine Gesamtlösung für Tanzschulen einzugliedern, in der neu zugekaufte Lieder für Tanzschulen automatisch klassifiziert werden. Diese Lösung zielt auf ein Problem ab, dass jede Tanzschule hat, nämlich dass neu gekaufte Tanzmusik entweder manuell von einem Mitarbeiter klassifiziert werden muss

oder die Musik unklassifiziert bleib und nur ein gewisser Teil der Lieder, von denen Tanzlehrer den passenden Tanzstil kennen, gespielt wird. Dieser Ansatz hätte den Vorteil, dass Tanzschulen den durch die Verwendung der Software entstandenen Gewinn sehr leicht vor eigenen Augen sehen, da sie die Personalkosten für die sehr monotone Arbeit der Klassifizierung einsparen könnten und keiner ihrer Mitarbeiter diese Arbeit unfreiwillig verrichten müsste. Außerdem wären bei diesem Ansatz die Marketingkosten minimal, da unser Interessent bereits in der Branche etabliert ist.

1.5 Bericht des Projektkoordinators

Innerhalb des Projektteams sind wir mit unterschiedlichen Schwerpunkten sehr stark aufgestellt.

Zwei Mitglieder unseres Projektes besuchen selbst seit Jahren einen Tanzkurs und bringen somit das nötige Fachwissen, wobei einer der beiden noch zusätzliche Erfahrungen mit Audiotechnik mit sich bringt. Ein weiteres Mitglied trägt das gebrauchte KI-Fachwissen ins Team und hat zusätzlich noch Erfahrungen mit Instrumentalmusik und Musiktheorie. Auch die Expertise in Design sowie in Benutzeroberflächen und Nutzererfahrung (UI/UX) wird durch ein weiteres Teammitglied eingebracht, womit das Team vollständig und interdisziplinär aufgestellt ist.

Die Zusammenarbeit innerhalb des Teams und mit der schulischen Projektbetreuung verlief über den gesamten Verlauf des Projektes gut, auch wenn Meinungsverschiedenheiten zu Einzelheiten natürlich nicht vollständig ausblieben. Durch die Bemühungen aller Beteiligten wurden diese Konflikte jedoch immer alsbald gelöst, sei es durch Kompromisse zum Wohl des Projekts, oder nur durch den kurzfristigen Aufbau eines Abstands von der eigenen Meinung, nur um das Thema am folgenden Tag erneut, mit einer frischen Einstellung, wieder aufzunehmen. Gerade bei teaminternen Designfragen half es auch oft, eine externe Meinung, wie die unserer Betreuer oder anderen Lehrpersonen im Bereich Design, hinzuzuziehen.

Besonders unsere Betreuer, Prof. Ing. Mag. Hans Christian Hammer und Dipl. Ing. Christian Aberger, haben uns bei Projektentscheidungen geholfen und unterstützt und uns stets in die richtige Richtung geleitet, wenn wir gefährdet waren, uns an einem

Einzelthema aufzuhängen. Regelmäßige Sprint-Reviews, halbwöchentliche Besprechungen im Team und Bewertungen durch unsere Lehrpersonen trugen nicht zuletzt zu einem strukturierten Werdegang unseres Projektes bei und halfen dabei, die Arbeitsmoral auch in Phasen mit wenigen unmittelbar sichtbaren Ergebnissen aufrecht zu erhalten

Dieser Werdegang verlief allerdings nicht ohne einige Herausforderungen. Eine respektable Hürde war für uns war zum Beispiel die Auswahl des richtigen KI-Modells und die Selektion der wichtigen Features, also der relevanten Eigenschaften der Eingabedaten, die anschließend analysiert werden. Unerwartet war für uns auch die Schwierigkeit des Auswertens von Aufnahmen auf einem Smartphone. Auch wenn die Klassifizierung mit fertigen, dreisekündigen Audiodateien schon gut funktionierte, wurden durch die Aufnahme eines solchen Clips am Smartphone manche Eigenschaften so verändert, dass die Klassifizierung nicht mehr zuverlässig erfolgte. Auch dieses Hindernis wurde durch ein erneutes Anpassen von KI-Modell und Features jedoch größtenteils überwunden.

Die in den bisherigen Jahren erlernten Inhalten an unserer Schule, gerade im Bereich Projektentwicklung und Programmieren, gaben uns die nötigen Grundlagen, die für das Projekt notwendig waren, auch wenn wir uns vieles Wissen noch selbst aneignen mussten. Auch diese Aneignung von Fachwissen im Bereich Künstliche Intelligenz oder Theoretische Physik konnte jedoch oft innerhalb des Lehrkörpers unserer Schule vonstattengehen.

Für das Projekt mussten keine externen Kosten aufgewendet werden, da für alles Technische die schulinterne Infrastruktur genutzt werden konnte. Das Projekt wurde im Rahmen des Unterrichtsfachs „Informationstechnische Projekte“ umgesetzt.

2. Abbildungs- und Literaturverzeichnis

Alle im Rahmen dieses Textes verwendeten Abbildungen wurden eigenständig erstellt, sodass wir die uneingeschränkten Urheberrechte an diesen Materialien besitzen. Für die inhaltlichen Informationen wurden ausschließlich Informationen aus eigenen Recherchen im Rahmen des Projekts und erarbeitetes Wissen genutzt; es wurden keine fremden urheberrechtlich geschützten Quellen übernommen.